

LAPORAN KOMPREHENSIF
CAPSTONE PROJECT
CODING CAMP 2026 POWERED BY DBS FOUNDATION



EDUPREDICT **MATH**
Real-Time Adaptive Learning Platform

Disusun Oleh:

Muhammad Ridho Darmawan	CFCC882D6Y2869	Full Stack Web Developer
Syifa Nadyva	CFCC470D6X2050	Full Stack Web Developer
Bayu Sujud Anugrah	CDCC323D6Y0840	Data Scientist
Siti Nazla Robysyah	CDCC595D6X1338	Data Scientist
Erlangga Sri Heryanto	CACC001D6Y1645	AI Engineer
Robert	CACC319D6Y0509	AI Engineer

BULAN JUNI
TAHUN 2026

DAFTAR ISI

DAFTAR ISI.....	2
BAGIAN I	
PROBLEM STATEMENT & LATAR BELAKANG.....	3
I. LATAR BELAKANG.....	3
II. RUMUSAN MASALAH.....	4
III. SOLUSI YANG DIUSULKAN.....	4
IV. PERTANYAAN BISNIS.....	5
BAGIAN II	
DATA UNDERSTANDING.....	5
I. SUMBER DATA.....	5
II. KARAKTERISTIK DATASET.....	5
III. STUKTUR DATA.....	6
IV. KETERBATASAN DATASET.....	7
V. HASIL DATA ASSESSMENT.....	7
BAGIAN 3	
DATA CLEANING.....	8
A. TUJUAN.....	8
B. FILTER KOLOM.....	8
C. FILTER BARIS SCAFFOLD.....	8
D. PENANGANAN MISSING VALUES.....	9
E. CLEANING FORMAT DESIMAL.....	9
F. DOKUMENTASI KETERBATASAN.....	9
BAGIAN 4	
MULTI-SKILL TAG HANDLING STRATEGY.....	10
A. LATAR BELAKANG MASALAH.....	10
B. STATISTIK MULTI-SKILL.....	10
C. OPSI PENANGANAN.....	10
D. PENANGANAN UNKNOWN SKILL NAME.....	11
BAGIAN 5	
SEQUENCE CONSTRUCTION & DATA SPLITTING.....	12
A. TUJUAN SEQUENCE CONSTRUCTION.....	12
B. PROSES SEQUENCE CONSTRUCTION.....	12
C. HASIL SEQUENCE CONSTRUCTION.....	12
D. PENDEKATAN DATA SPLITTING.....	13
E. HASIL DATA SPLITTING.....	13
BAGIAN 6	
EXPLORATORY DATA ANALYSIS (EDA).....	14
A. PENDEKATAN EDA.....	14
B. EDA GLOBAL.....	14
C. EDA KHUSUS KNOWLEDGE TRACING.....	16

BAGIAN 7	
KESIMPULAN & REKOMENDASI.....	17

BAGIAN I

PROBLEM STATEMENT & LATAR BELAKANG

I. LATAR BELAKANG

Sistem pembelajaran matematika yang berlaku saat ini masih menerapkan pendekatan yang seragam untuk seluruh siswa tanpa mempertimbangkan perbedaan kemampuan, kecepatan belajar, dan pola interaksi masing-masing individu. Pendekatan ini dikenal sebagai *one-size-fits-all*, di mana seluruh siswa menerima materi, metode pengajaran, dan evaluasi yang identik meskipun kebutuhan belajar mereka berbeda-beda. Kondisi ini menjadi semakin krusial pada pembelajaran matematika yang memiliki struktur konsep hierarkis di mana pemahaman pada konsep dasar menjadi prasyarat untuk menguasai konsep yang lebih kompleks, sehingga keterlambatan deteksi kesulitan belajar dapat berdampak panjang terhadap performa siswa secara keseluruhan.

Selain itu, evaluasi pembelajaran yang ada saat ini umumnya bersifat reaktif, yaitu dilakukan setelah siswa menyelesaikan seluruh rangkaian proses belajar. Akibatnya, kesulitan belajar baru terdeteksi setelah kegagalan terjadi, bukan sebelum atau selama proses berlangsung. Keterlambatan deteksi ini menyebabkan intervensi pembelajaran tidak dapat diberikan pada waktu yang tepat sehingga efektivitasnya menjadi terbatas. Kondisi ini diperburuk oleh minimnya intervensi personal yang disesuaikan dengan kebutuhan spesifik setiap siswa sehingga guru sulit memantau perkembangan belajar seluruh siswa secara individual dalam waktu yang bersamaan.

II. RUMUSAN MASALAH

Berdasarkan latar belakang tersebut, terdapat tiga permasalahan utama yang menjadi fokus project EduPredict Math:

1. Sistem pembelajaran yang bersifat *one-size-fits-all* tidak mampu mengakomodasi perbedaan kemampuan dan pola belajar individual siswa, sehingga siswa yang mengalami kesulitan tidak mendapatkan perhatian yang proporsional dibandingkan siswa yang sudah menguasai materi.
2. Evaluasi pembelajaran yang bersifat reaktif menyebabkan keterlambatan dalam mendeteksi kesulitan belajar siswa. Kesulitan baru teridentifikasi setelah siswa mengalami kegagalan, padahal intervensi yang diberikan lebih awal akan jauh lebih efektif dalam mencegah akumulasi kesulitan belajar.
3. Minimnya intervensi personal yang adaptif membuat siswa tidak mendapatkan bantuan yang disesuaikan dengan kebutuhan spesifik mereka. Sistem yang ada belum mampu memberikan rekomendasi pembelajaran yang dipersonalisasi berdasarkan pola interaksi dan tingkat penguasaan konsep masing-masing siswa.

III. SOLUSI YANG DIUSULKAN

Untuk menjawab ketiga permasalahan tersebut, dikembangkan **EduPredict Math** yaitu sebuah platform pembelajaran berbasis web yang memanfaatkan pendekatan *Knowledge Tracing* berbasis *Deep Learning* untuk menganalisis pola interaksi siswa secara temporal. Sistem ini dirancang untuk memprediksi kemungkinan keberhasilan siswa pada konsep matematika berikutnya secara *real-time*, sehingga intervensi pembelajaran dapat diberikan secara preventif sebelum kegagalan terjadi.

Pendekatan *Knowledge Tracing* dipilih berdasarkan penelitian Chris Piech et al. (2015) yang memperkenalkan *Deep Knowledge Tracing*, sebuah model berbasis *Long Short-Term Memory* (LSTM) yang mampu memodelkan pengetahuan siswa sebagai fungsi dari urutan interaksi mereka dengan soal-soal latihan. Model ini terbukti menghasilkan prediksi yang lebih akurat dibandingkan metode *Knowledge Tracing* konvensional dengan memanfaatkan pola sekuensial dari riwayat jawaban siswa (Piech et al., 2015).

IV. PERTANYAAN BISNIS

Untuk mendukung pengembangan sistem ini, terdapat tujuh pertanyaan bisnis yang diangkat, diantaranya:

1. Berapa nilai probabilitas sebagai ambang batas (threshold) untuk memicu intervensi sistem selama proses pengerjaan kuis?
2. Apakah model menunjukkan bias pada kelompok siswa tertentu berdasarkan pola performa atau karakteristik pembelajaran?
3. Apakah intervensi pembelajaran yang difokuskan pada materi dengan probabilitas penguasaan terendah lebih efektif dalam meningkatkan performa siswa dibandingkan strategi lainnya?
4. Bagaimana pengaruh intervensi adaptif yang diberikan di tengah kuis terhadap nilai performa akhir siswa?
5. Bagaimana skema kelanjutan sesi kuis setelah intervensi (melanjutkan atau mengulang) mempengaruhi hasil evaluasi dan pengalaman belajar siswa?
6. Bagaimana pemanfaatan data historis sesi sebelumnya (pre-intervention) mempengaruhi akurasi prediksi dan evaluasi performa siswa?
7. Seberapa cepat sistem dapat menghasilkan prediksi dan memberikan intervensi secara *real-time* tanpa mengganggu pengalaman penggunaan?

BAGIAN II

DATA UNDERSTANDING

I. SUMBER DATA

Dataset yang digunakan dalam project ini adalah **ASSISTments 2009-2010 Skill Builder Dataset**, sebuah dataset publik yang dikumpulkan dari platform pembelajaran matematika adaptif ASSISTments selama tahun ajaran 2009-2010. Dataset ini merupakan salah satu benchmark standar yang paling banyak digunakan dalam penelitian Knowledge Tracing, termasuk dalam paper Deep Knowledge Tracing oleh Piech et al. (2015) yang menjadi landasan teoretis project ini.

Dataset tersedia dalam dua versi yaitu versi original dan versi corrected. Versi corrected digunakan dalam project ini karena duplikasi data yang ditemukan pada versi original sudah dihapus sehingga menghasilkan data yang lebih bersih dan representatif. Dataset dapat diakses melalui laman resmi ASSISTments di <https://sites.google.com/site/assistmentsdata/home/2009-2010-assistment-data/skill-builder-data-2009-2010>.

II. KARAKTERISTIK DATASET

Dataset ASSISTments 2009-2010 Skill Builder memiliki karakteristik khusus yang membedakannya dari dataset pembelajaran lain. Sistem ASSISTments dirancang sebagai platform *skill builder* di mana siswa harus menjawab tiga soal secara benar berturut-turut untuk menyelesaikan satu assignment. Jika siswa menggunakan fitur hint atau *Break this Problem Into Steps*, soal akan otomatis ditandai sebagai salah meskipun siswa akhirnya mengetahui jawabannya. Siswa juga langsung mengetahui apakah jawabannya benar atau salah setelah setiap pengerjaan soal.

Dataset ini terdiri dari **346.860 baris dan 31 kolom** yang mencakup **4.217 siswa unik** dengan interaksi terhadap **26.688 soal matematika unik** yang mencakup berbagai konsep matematika. Setiap baris merepresentasikan satu interaksi antara satu siswa dengan satu soal, dengan catatan bahwa jika satu soal memiliki dua skill tagging, keduanya digabung dalam satu baris.

```

... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 346860 entries, 0 to 346859
Data columns (total 31 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Unnamed: 0                            346860 non-null  int64
1   order_id                             346860 non-null  int64
2   assignment_id                         346860 non-null  int64
3   user_id                              346860 non-null  int64
4   assistment_id                         346860 non-null  int64
5   problem_id                           346860 non-null  int64
6   original                             346860 non-null  int64
7   correct                              346860 non-null  int64
8   attempt_count                         346860 non-null  int64
9   ms_first_response                    346860 non-null  int64
10  tutor_mode                           346860 non-null  object
11  answer_type                          346860 non-null  object
12  sequence_id                          346860 non-null  int64
13  student_class_id                     346860 non-null  int64
14  position                             346860 non-null  int64
15  type                                 346860 non-null  object
16  base_sequence_id                     346860 non-null  int64
17  skill_id                             283105 non-null  object
18  skill_name                           274590 non-null  object
19  teacher_id                           346860 non-null  int64
20  school_id                            346860 non-null  int64
21  hint_count                           346860 non-null  int64
22  hint_total                           346860 non-null  int64
23  overlap_time                         346860 non-null  int64
24  template_id                          346860 non-null  int64
25  answer_id                            40042 non-null   float64
26  answer_text                          269230 non-null  object
27  first_action                         346860 non-null  int64
28  bottom_hint                          59857 non-null   float64
29  opportunity                           346860 non-null  int64
30  opportunity_original                 275458 non-null  float64
dtypes: float64(3), int64(22), object(6)
memory usage: 82.0+ MB

```

III. STUKTUR DATA

Dataset memiliki 31 kolom yang dapat dikelompokkan ke dalam empat kategori utama berdasarkan perannya dalam analisis:

1. **Identitas Siswa dan Konteks** mencakup kolom `order_id` sebagai penanda urutan kronologis interaksi yang digunakan sebagai proxy timestamp karena tidak tersedia kolom datetime eksplisit, `user_id` sebagai identitas unik setiap siswa, `assignment_id` sebagai identitas tugas, dan `problem_id` sebagai identitas spesifik setiap butir soal.
2. **Identitas Konsep** mencakup kolom `skill_id` sebagai identitas numerik konsep matematika yang dapat berupa composite skill dengan format gabungan seperti `1_13`, dan `skill_name` sebagai nama deskriptif konsep matematika yang membantu interpretasi hasil analisis.
3. **Metrik Performa dan Interaksi** mencakup kolom `correct` sebagai label jawaban siswa dengan nilai 1 untuk benar dan 0 untuk salah, `attempt_count` sebagai jumlah percobaan per soal, `ms_first_response` sebagai waktu respon pertama dalam milidetik, dan `hint_count` sebagai jumlah hint yang digunakan siswa per soal.

4. **Atribut Pendukung** mencakup kolom original yang membedakan soal utama dari soal scaffold, dan opportunity yang mencatat urutan keberapa siswa bertemu dengan konsep yang sama, kolom ini sangat berguna untuk analisis learning progression.

IV. KETERBATASAN DATASET

Terdapat dua keterbatasan utama yang perlu dicatat dan didokumentasikan secara formal sebagai bagian dari transparansi analisis. **Keterbatasan pertama** adalah tidak tersedianya kolom timestamp eksplisit dalam format datetime. Dataset ini tidak memiliki informasi kapan tepatnya suatu interaksi terjadi dalam format tanggal dan waktu. Sebagai solusi, kolom `order_id` digunakan sebagai proxy urutan kronologis karena nilainya unik dan berurutan secara sekuensial semakin besar nilai `order_id`, semakin belakangan interaksi tersebut terjadi. Namun keterbatasan ini menyebabkan analisis berbasis delta waktu antar sesi tidak dapat dilakukan secara akurat karena selisih antar nilai `order_id` tidak merepresentasikan selisih waktu yang sesungguhnya.

Keterbatasan kedua adalah adanya anomali pada kolom `ms_first_response` berupa nilai negatif sebanyak 7 baris, nilai nol sebanyak 310 baris, dan nilai ekstrem lebih dari 1 jam sebanyak 151 baris. Total anomali ini hanya mencakup 468 baris atau 0.13% dari total data sehingga dampaknya terhadap keseluruhan analisis relatif kecil. Keputusan tim adalah mendokumentasikan anomali ini sebagai keterbatasan tanpa melakukan filtering.

V. HASIL DATA ASSESSMENT

Sebelum proses cleaning dilakukan, dilakukan data assessment menyeluruh untuk memahami kondisi awal dataset. Hasil assessment menunjukkan bahwa dataset tidak memiliki duplikasi baris sama sekali. Dari sisi missing values, ditemukan dua kolom dengan missing values sangat tinggi yaitu `answer_id` sebesar 88.45% dan `bottom_hint` sebesar 82.76% yang mengindikasikan kedua kolom ini tidak cukup informatif untuk digunakan dalam analisis. Kolom `skill_name` missing 20.84% dan `skill_id` missing 18.38% kedua kolom ini krusial untuk Knowledge Tracing sehingga baris tanpa nilai pada kolom tersebut perlu ditangani pada tahap cleaning.

Dari sisi distribusi jawaban, overall correctness rate berada di 64.5% yang menunjukkan dataset cukup balanced dan tidak terlalu didominasi oleh satu kelas. Namun perlu dicatat bahwa sebagian dari label `correct=0` bukan merupakan kegagalan murni melainkan hasil dari penggunaan hint, kondisi yang disebut sebagai hint contamination dan akan dibahas lebih lanjut pada tahap analisis. Dari sisi tipe data, kolom `skill_id` bertipe object dengan format gabungan seperti 1_13, 2_37_70, dan 2_37_48_77 yang mengindikasikan satu soal dapat memiliki lebih dari satu skill tagging sekaligus. Kondisi ini menjadi salah satu tantangan utama dalam proses analisis.

BAGIAN 3

DATA CLEANING

A. TUJUAN

Proses data cleaning bertujuan untuk memastikan dataset yang digunakan dalam analisis dan modeling bebas dari noise, inkonsistensi, dan informasi yang tidak relevan. Tahap ini menghasilkan dataset bersih `df_filtered` dengan 251.405 baris dan 9 kolom yang siap digunakan untuk sequence construction dan EDA.

B. FILTER KOLOM

Dari 31 kolom dataset asli, hanya 10 kolom yang dipertahankan berdasarkan relevansinya terhadap analisis dan modeling yaitu `order_id`, `user_id`, `skill_id`, `skill_name`, `correct`, `original`, `hint_count`, `attempt_count`, `ms_first_response`, dan `opportunity`. Kolom lainnya dieksklusi karena tidak digunakan untuk modeling, memiliki missing values yang sangat tinggi, atau hanya berperan sebagai identitas sistem.

C. FILTER BARIS SCAFFOLD

Dataset ASSISTments mengandung dua jenis soal yaitu soal original (`original=1`) dan soal scaffold (`original=0`). Soal scaffold adalah sub-problem yang muncul otomatis ketika siswa gagal mengerjakan soal utama, bukan bagian dari alur pembelajaran yang independen. Sebanyak **71.402 baris scaffold atau 20.6%** dari total data dieksklusi untuk memastikan sequence yang dibangun hanya mencerminkan interaksi siswa dengan soal-soal utama.

D. PENANGANAN MISSING VALUES

Kolom `skill_name` merupakan identitas utama konsep matematika yang digunakan dalam sequence construction. Baris tanpa nilai pada kolom ini tidak dapat direpresentasikan dalam urutan interaksi siswa sehingga harus dihapus. Sebanyak **24.053 baris atau 9.56%** dari data setelah filter scaffold dihapus. Setelah penghapusan, seluruh kolom kritis termasuk `skill_id` bebas dari missing values dan mengkonfirmasi bahwa baris tanpa `skill_name` juga tidak memiliki `skill_id`.

E. CLEANING FORMAT DESIMAL

Ditemukan 22 nilai `skill_id` berformat desimal seperti 311.0 dan 323.0 yang terjadi akibat konversi tipe data otomatis oleh pandas. Seluruh format desimal dibersihkan menjadi format integer string yang konsisten seperti 311 dan 323 untuk memastikan konsistensi mapping pada tahap berikutnya.

F. DOKUMENTASI KETERBATASAN

Dua kondisi berikut didokumentasikan sebagai keterbatasan dan tidak ditangani melalui penghapusan data. Pertama, **hint contamination** sebanyak 59.841 baris atau 17.3% memiliki `correct=0` bukan karena jawaban salah murni melainkan karena penggunaan hint yang secara otomatis ditandai salah oleh sistem ASSISTments. Kondisi ini dipertahankan karena tetap merupakan informasi valid tentang perilaku siswa namun perlu diperhatikan AI Engineer dalam interpretasi label negatif. Kedua, **anomali response time** yaitu sebanyak 468 baris dengan nilai `ms_first_response` negatif, nol, atau ekstrem didokumentasikan.

BAGIAN 4

MULTI-SKILL TAG HANDLING STRATEGY

A. LATAR BELAKANG MASALAH

Dalam baseline Knowledge Tracing, asumsi dasarnya adalah **1 interaksi = 1 konsep**. Namun ditemukan bahwa kolom skill_id pada dataset ini dapat berisi lebih dari satu tag sekaligus dalam format gabungan seperti 1_13, 2_37_70, dan 2_37_48_77 — mengindikasikan satu soal dapat mengujikan lebih dari satu konsep matematika secara bersamaan. Kondisi ini perlu ditangani sebelum sequence construction dilakukan karena langsung mempengaruhi representasi konsep dalam model DKT.

B. STATISTIK MULTI-SKILL

Dari total 251.405 interaksi bersih, ditemukan bahwa **44.827 interaksi atau 17.83%** memiliki composite skill_id. Distribusi jumlah tag per interaksi menunjukkan bahwa interaksi dengan dua tag mendominasi sebanyak 38.794 interaksi, diikuti tiga tag sebanyak 4.354 interaksi, dan empat tag sebanyak 1.679 interaksi. Total unique skill_id yang tersedia adalah **136** yang terdiri dari 93 single skill dan 43 composite skill.

C. OPSI PENANGANAN

Option A: Drop Multi-Skill tidak tersedia karena proporsi 17.83% terlalu besar untuk dibuang dan akan menyebabkan hilangnya data serta rusaknya integritas sequence pembelajaran siswa.

Option B: Keep as Composite Skill mempertahankan composite skill_id sebagai satu representasi konsep unik. Pendekatan ini menjaga integritas sequence dan tidak ada data yang hilang namun menyebabkan jumlah unique concept_id lebih besar.

Option C: Take First Skill mengambil tag pertama saja dari composite skill. Opsi ini tidak dipilih karena dapat menyebabkan misleading, informasi konseptual yang sebenarnya multidimensi dipaksa menjadi satu dimensi.

Option D: Separate Jadi Multi-Rows memecah composite skill menjadi beberapa baris terpisah. Opsi ini tidak dipilih karena berpotensi menyebabkan sequence ambiguity, urutan interaksi siswa tidak lagi merepresentasikan alur belajar yang sesungguhnya

Kami menggunakan Option B yaitu **Keep as Composite Skill** berdasarkan pertimbangan bahwa proporsi 17.83% terlalu signifikan untuk diabaikan dan membuang data tersebut akan merusak integritas sequence pembelajaran siswa. Setiap kombinasi skill diperlakukan sebagai satu composite concept unik dalam proses Knowledge Tracing.

D. PENANGANAN UNKNOWN SKILL NAME

Setelah proses explode dilakukan untuk keperluan EDA, ditemukan **21 tag** yang tidak memiliki padanan skill_name di dataset. Untuk menyelesaikan masalah ini, dilakukan mapping menggunakan file referensi skill_builder_data.csv yang merupakan versi original dataset sebelum composite skill di-collapse. Dari 21 unknown tag, **18 tag berhasil dimapping** ke nama resmi melalui file referensi, **2 tag** yaitu 48 dan 63 ditemukan melalui pengecekan di dataset mentah dengan nama *Equivalent Fractions* dan *Estimation*, sehingga hanya **3 tag yang benar-benar tidak tersedia** yaitu tag 37, 102, dan 104 diberi label *Unresolved Skill (X)* sebagai representasi yang lebih informatif.

BAGIAN 5

SEQUENCE CONSTRUCTION & DATA SPLITTING

A. TUJUAN SEQUENCE CONSTRUCTION

Sequence construction adalah tahap mengubah data tabular menjadi urutan interaksi siswa yang mencerminkan proses pembelajaran secara temporal. Output tahap ini menjadi format input utama model Deep Knowledge Tracing yang akan dibangun oleh AI Engineer.

B. PROSES SEQUENCE CONSTRUCTION

Data yang sudah bersih diurutkan berdasarkan `user_id` dan `order_id`, kemudian dikelompokkan per siswa menggunakan operasi `groupby`. Setiap siswa direpresentasikan sebagai sequence pasangan (`skill_id`, `correct`) yang mencerminkan urutan interaksi mereka secara kronologis. Format ini mengikuti konvensi yang digunakan dalam paper Deep Knowledge Tracing oleh Piech et al. (2015) di mana setiap langkah pembelajaran direpresentasikan sebagai konsep dan hasil jawaban.

C. HASIL SEQUENCE CONSTRUCTION

Proses sequence construction menghasilkan **4.151 siswa** dengan sequence interaksi yang siap digunakan untuk modeling. Statistik panjang sequence menunjukkan distribusi yang sangat tidak merata, mayoritas siswa memiliki sequence pendek namun ada sebagian kecil siswa dengan sequence sangat panjang yang menarik nilai rata-rata jauh di atas median.

```
***
Sequence berhasil dibuat!
Total siswa : 4,151

Statistik Panjang Sequence
Min panjang sequence   : 1
Max panjang sequence   : 925
Mean panjang sequence  : 60.6
Median panjang sequence : 19.0
```

D. PENDEKATAN DATA SPLITTING

Data splitting dilakukan menggunakan **student-level split** di manaseluruh sequence interaksi satu siswa hanya berada di satu subset saja dan tidak terbagi antara train, validation, maupun test. Pendekatan ini dipilih untuk menghindari data leakage yang akan terjadi jika splitting dilakukan di level interaksi, di mana model dapat mengenal sebagian pola belajar siswa dari data training dan menghasilkan evaluasi yang tidak objektif. Rasio splitting yang digunakan adalah **70:15:15** untuk train, validation, dan test berdasarkan kesepakatan tim. Validation set ditambahkan atas permintaan AI Engineer untuk memantau performa model selama proses training.

E. HASIL DATA SPLITTING

Verifikasi overlap menunjukkan tidak ada satu pun siswa yang sequence-nya terbagi antara ketiga subset mengkonfirmasi bahwa data leakage berhasil dihindari sepenuhnya. Model nantinya akan dievaluasi pada siswa yang benar-benar belum pernah dilihat selama training, mencerminkan kondisi nyata penggunaan sistem EduPredict Math untuk memprediksi performa siswa baru.

```
***
Total siswa : 4,151

Siswa train : 2,905 (70.0%)
Siswa val   : 623 (15.0%)
Siswa test  : 623 (15.0%)

Verifikasi Split
Shape train_df : (2905, 7)
Shape val_df   : (623, 7)
Shape test_df  : (623, 7)

Overlap train & val : 0
Overlap train & test : 0
Overlap val & test  : 0
```

BAGIAN 6

EXPLORATORY DATA ANALYSIS (EDA)

A. PENDEKATAN EDA

EDA dilakukan dalam dua tahap yaitu **EDA Global** menggunakan data tabular `df_filtered` untuk menganalisis pola interaksi secara keseluruhan, dan **EDA Khusus Knowledge Tracing** menggunakan data sequence `seq_df` untuk menganalisis karakteristik urutan interaksi per siswa. Untuk analisis berbasis `skill_name`, digunakan data hasil `explode df_exploded` yang memisahkan setiap tag dari composite skill menjadi baris individual sehingga seluruh konsep ikut terhitung secara akurat.

B. EDA GLOBAL

1. Distribusi Jawaban Benar dan Salah

Dari 251.405 interaksi bersih, sebanyak **166.344 interaksi atau 66.17%** dijawab dengan benar dan **85.061 interaksi atau 33.83%** dijawab salah. Rasio ini menunjukkan dataset cukup balanced dan tidak terlalu didominasi oleh satu kelas, kondisi yang baik untuk pelatihan model karena model tidak akan mudah bias ke prediksi "selalu benar".

2. Frekuensi Pengerjaan per Skill

Analisis frekuensi pengerjaan per skill dilakukan untuk mengidentifikasi konsep matematika mana yang paling sering dan paling jarang dikerjakan oleh siswa. Informasi ini penting untuk memahami distribusi exposure siswa terhadap setiap konsep dalam dataset. Dari 101 skill matematika unik, terdapat ketimpangan distribusi yang sangat signifikan. **Conversion of Fraction Decimals Percents** mendominasi dengan 18.749 interaksi, diikuti **Circle Graph** dengan 18.399 interaksi dan **Equation Solving Two or Fewer Steps** dengan 17.311 interaksi. Di sisi lain, **Reading a Ruler or Scale** dan **Finding Slope from Ordered Pairs** hanya memiliki 5 interaksi masing-masing. Ketimpangan ini mengindikasikan bahwa model DKT kemungkinan akan memiliki performa prediksi yang lebih baik pada skill dengan frekuensi tinggi dibandingkan skill yang jarang muncul dalam dataset akibat keterbatasan data untuk proses pembelajaran model.

3. Corectness Rate per Skill

Analisis correctness rate per skill dilakukan untuk mengidentifikasi konsep matematika mana yang paling mudah dan paling sulit dikuasai oleh siswa. Informasi ini penting sebagai landasan untuk menentukan prioritas intervensi pembelajaran pada konsep dengan tingkat penguasaan terendah. Variasi tingkat kesulitan antar skill sangat signifikan. **Nets of 3D Figures** menjadi skill termudah dengan correctness rate **95%**, sedangkan **Rotations** menjadi skill tersulit dengan correctness rate **13.15%** dari 441 interaksi yang representatif. Skill-skill dengan correctness rate rendah dan jumlah interaksi yang representatif seperti Rotations, Solving Systems of Linear Equations (19.23%),

dan Surface Area Cylinder (31.57%) menjadi kandidat utama prioritas intervensi adaptif dalam sistem EduPredict Math.

Penting dicatat bahwa baik grafik Frekuensi Pengerjaan per Skill dan Corectness Rate per Skill dikelompokkan berdasarkan kolom skill_name sehingga untuk mendapatkan grafik yang benar-benar akurat perlu menggunakan *clean data* yang telah diexplode tujuannya adalah agar grafik benar-benar mengakomodir tiap skill yang diterapkan siswa pada tiap soal composite.

4. **Analisis Hint Usage**

Analisis hint usage dilakukan untuk memahami seberapa besar pengaruh penggunaan hint terhadap pola jawaban siswa. Hal ini penting karena penggunaan hint secara otomatis menandai jawaban sebagai salah dalam sistem ASSISTments, sehingga perlu dipahami distribusinya agar tidak terjadi bias dalam interpretasi label correct oleh model. Sebanyak **82.7% interaksi** dilakukan tanpa hint, **4.73%** menggunakan hint sedikit antara 1 hingga 2 kali, dan **9.21%** menggunakan hint banyak lebih dari 2 kali. Correctness rate menunjukkan pola yang sangat ekstrem, siswa tanpa hint memiliki correctness rate **76.88%** sedangkan yang menggunakan hint mendekati **0%** yang sepenuhnya mengkonfirmasi mekanisme ASSISTments yang otomatis menandai jawaban sebagai salah ketika hint digunakan.

5. **Analisis Attempt Count**

Analisis attempt count dilakukan untuk memahami pola pengulangan siswa dalam menjawab soal. Jumlah percobaan yang tinggi pada satu soal dapat mengindikasikan tingkat kesulitan materi atau persistensi siswa dalam memahami konsep. Informasi ini berguna untuk melengkapi pemahaman tentang behavior siswa selama proses pembelajaran.

6. **Analisis Opportunity**

Analisis opportunity dilakukan untuk memahami pola pengulangan siswa dalam mengerjakan soal dengan konsep yang sama. Kolom opportunity mencatat urutan seberapa siswa bertemu dengan suatu konsep, sehingga dapat digunakan untuk menganalisis learning progression siswa secara temporal. Semakin tinggi nilai opportunity, semakin sering siswa berinteraksi dengan konsep tersebut. Distribusi opportunity menunjukkan bahwa **45.25% interaksi** berada di kategori awal (opportunity 1-5) dan **40.15%** di kategori menengah (opportunity 6-20). Menariknya, correctness rate tidak meningkat secara linear seiring bertambahnya opportunity, kategori lanjut justru memiliki correctness rate terendah sebesar 62.15%, mengindikasikan siswa yang masih berada di opportunity tinggi adalah mereka yang mengalami kesulitan signifikan pada konsep tersebut.

C. EDA KHUSUS KNOWLEDGE TRACING

1. **Analisis Behavior Siswa**

Analisis behavior siswa dilakukan untuk memahami pola dan karakteristik cara siswa berinteraksi dengan soal selama proses pembelajaran. Analisis ini mencakup distribusi correctness rate per siswa, penggunaan hint per siswa, dan konsistensi performa siswa secara keseluruhan. Insight yang dihasilkan akan membantu mengidentifikasi kelompok siswa berdasarkan karakteristik belajarnya. Rata-rata correctness rate per siswa berada di **62.30%** dengan sebaran yang cukup lebar yaitu nilai minimum 0% dan maksimum 100% menunjukkan keberagaman kemampuan yang sangat signifikan. Dari kategorisasi, **40.42% siswa** berada di kategori sedang (50-75%), **34.47%** berkategori tinggi (>75%), dan **25.10%** berkategori rendah (<50%). Satu dari empat siswa memiliki correctness rate di bawah 50%. Kelompok ini menjadi target utama intervensi adaptif sistem EduPredict Math.

2. **Analisis Learning Progression**

Analisis learning progression dilakukan untuk memahami bagaimana performa siswa berkembang seiring bertambahnya pengalaman mengerjakan soal. Analisis ini menggunakan kolom opportunity sebagai representasi urutan pertemuan siswa dengan suatu konsep, sehingga dapat dilihat apakah terdapat pola peningkatan penguasaan konsep secara temporal pada kelompok siswa secara keseluruhan. Learning curve menunjukkan pola yang sangat informatif. Pada opportunity pertama, correctness rate berada di 59.44%, nilai terendah dalam keseluruhan kurva. Lonjakan terbesar terjadi antara opportunity pertama dan kedua dengan peningkatan 7.6 poin persentase menjadi 67.04%. Setelah opportunity kedua, correctness rate cenderung stabil di kisaran 68-71% tanpa peningkatan signifikan. Pola ini mengindikasikan bahwa **interaksi awal siswa dengan suatu konsep adalah yang paling informatif** untuk memprediksi pola penguasaan selanjutnya. Temuan ini relevan untuk pengembangan model DKT karena menunjukkan bahwa data historis awal memiliki bobot prediktif yang lebih tinggi dibandingkan interaksi berikutnya.

BAGIAN 7

KESIMPULAN & REKOMENDASI

Hasil analisis menunjukkan bahwa dataset ASSISTments 2009–2010 memiliki fitur dan karakteristik yang cukup memadai untuk membangun sistem Knowledge Tracing pada EduPredict Math. Proses pembersihan data dan pembuatan sequence berhasil menghasilkan data yang siap digunakan untuk pemodelan tanpa kehilangan data secara signifikan. Hasil EDA menunjukkan bahwa siswa memiliki interaksi yang beragam terhadap tiap konsep matematika dimana beberapa konsep memiliki `correctness` yang lebih tinggi sedangkan yang lainnya lebih rendah. Interaksi pertama siswa pada suatu konsep memiliki hubungan nilai prediktif yang tinggi yakni performa siswa pada pertemuan-pertemuan pertama dengan suatu konsep dapat memberikan gambaran kuat tentang bagaimana penguasaan konsep tersebut di masa berikutnya. Dari analisis learning progression, peningkatan terbesar terjadi antara opportunity pertama dan kedua, kemudian kurva cenderung stabil. Temuan ini mendukung penggunaan Tracing Pengetahuan Mendalam untuk memprediksi prestasi siswa dan menyediakan intervensi pembelajaran yang lebih personal secara real-time.

Berdasarkan temuan yang didapatkan selama proses analisis, terdapat beberapa rekomendasi yang dapat menjadi acuan dalam tahap pengembangan selanjutnya:

1. Mengembangkan model Deep Knowledge Tracing menggunakan sequence data yang telah disiapkan untuk memprediksi tingkat penguasaan konsep siswa secara real-time.
2. Memprioritaskan intervensi adaptif pada konsep dengan tingkat keberhasilan rendah, seperti Rotations, Solving Systems of Linear Equations, dan Surface Area Cylinder.
3. Melakukan evaluasi lebih lanjut terhadap pengaruh penggunaan hint terhadap performa model agar prediksi yang dihasilkan lebih akurat.
4. Mengintegrasikan hasil prediksi ke dalam dashboard EduPredict Math untuk menampilkan tingkat penguasaan konsep dan rekomendasi pembelajaran yang dipersonalisasi bagi siswa.